Guía de aprendizaje No. 1: Resumen de temas del trimestre I

Edward Ricardo Gonzalez

Centro de Materiales y Ensayos, Servicio Nacional de Aprendizaje (SENA)

Programa técnico en Procesamiento de Datos para Modelos de Inteligencia Artificial, Trimestre II

Instructora: Ing. Nathalia Martinez Vargas

31 de octubre de 2026

Índice

Actividades **3**

Actividades de reflexión inicial 3

Actividades de contextualización e identificación de conocimientos 5

Actividades de apropiación 6

Ficha de caracterización de variables 7

Limpieza de datos 9

Análisis exploratorio de datos 9

Actividades de transferencia del conocimiento 9

Condiciones de entrega **10**

Referencias **10**

Guía de aprendizaje No. 1: Resumen de temas del trimestre I

Este documento responde las preguntas de reflexión inicial de la Guía de Aprendizaje No. 1 y presenta las actividades del proyecto integrador. A partir del caso de la sonda Mars Climate Orbiter, se destaca la importancia de comprender, documentar y validar los datos antes de procesarlos o utilizarlos para tomar decisiones.

Actividades

Actividades de reflexión inicial

Caso de estudio: Mars Climate Orbiter

La pérdida de la sonda Mars Climate Orbiter muestra que los datos deben interpretarse con sus unidades y convenciones correctas. En el caso descrito en la guía, un equipo suministró datos de empuje en libras-fuerza y el software de navegación los interpretó como newtons, sin realizar la conversión correspondiente (Jet Propulsion Laboratory, 1999; Mars Climate Orbiter Mishap Investigation Board, 2000).

1. **¿Qué consecuencias podría tener para una empresa procesar un archivo de Excel sin saber si la columna "Ventas" está expresada en pesos colombianos, dólares o euros?**

   Si se mezclan monedas o se interpretan con una unidad equivocada, la empresa podría sumar y comparar cantidades que no son equivalentes y calcular incorrectamente sus ingresos, márgenes, presupuestos o comisiones. Por ejemplo, tratar una cifra en dólares como si estuviera expresada en pesos colombianos alteraría considerablemente el valor reportado. Esto podría conducir a decisiones equivocadas sobre precios, inventario e inversiones, generar errores en las obligaciones tributarias, ocasionar pérdidas económicas y reducir la confianza en los informes. Antes de combinar o analizar valores monetarios, es necesario identificar la moneda y el periodo y, cuando corresponda, documentar la tasa y la fecha de conversión.

2. **¿Por qué la ficha de caracterización de variables (diccionario de datos) es un paso fundamental antes de escribir código en Python o SQL?**

La ficha documenta qué representa cada variable y cómo debe interpretarse. Debe incluir, entre otros aspectos, su definición, tipo de dato, unidad o moneda, formato, valores permitidos, origen y significado de los datos faltantes. Esta información permite elegir las operaciones y validaciones adecuadas, detectar inconsistencias y evitar que el código procese las variables a partir de supuestos equivocados. Además, facilita que otras personas comprendan y reproduzcan el análisis. El caso de la sonda muestra que un dato numérico sin contexto —en particular, sin una unidad explícita— puede producir resultados incorrectos aunque el software funcione según lo programado.

3. **Si recibe un archivo lleno de números y sin metadatos, ¿cuál debería ser su primera acción antes de aplicar cálculos o transformaciones?**

   No modificaría ni interpretaría los valores de inmediato. Primero conservaría una copia intacta del archivo y consultaría a la persona responsable de los datos para obtener el diccionario de datos y los metadatos: el significado de cada columna, las unidades, la moneda, el periodo, la población cubierta, las reglas de codificación, el origen y el tratamiento de los valores nulos. Después contrastaría esa documentación con una inspección inicial del archivo —nombres de columnas, tipos de datos, rangos, formatos y algunos registros— y registraría cualquier duda. Si no fuera posible confirmar el significado de los datos, comunicaría esa limitación y evitaría presentar conclusiones como si fueran confiables.

4. **¿De qué sirve tener millones de datos y las mejores herramientas si se comete un error al comprender la estructura de los datos?**

   El volumen de datos no corrige una interpretación equivocada; puede amplificar sus efectos. Si una unidad, categoría, fecha o relación se interpreta mal, el error se propaga a los cálculos, modelos y visualizaciones. Así, las herramientas pueden generar resultados que parecen precisos, pero que se basan en una premisa falsa. Las decisiones automatizadas derivadas de esos resultados también pueden afectar a muchas personas o transacciones. Por eso, antes de priorizar el tamaño de los datos o la complejidad de las herramientas, es fundamental

verificar su significado, estructura, calidad y contexto.

Actividades de contextualización e identificación de conocimientos

Fase 1 del proyecto integrador. Se seleccionó un conjunto de datos sobre beneficiarios. Las siguientes preguntas de negocio se plantearon a partir de las variables disponibles.

1. **¿Cómo influye el género del titular en el estado del beneficiario (activo o inactivo)?**

   La Tabla 1 resume los conteos disponibles. La tasa de actividad es de 79,0 % para las mujeres y de 81,3 % para los hombres, una diferencia descriptiva de 2,4 puntos porcentuales. Estos datos no bastan para afirmar que la diferencia sea estadísticamente significativa ni que el género cause el estado del beneficiario.

   Tabla 1

   Estado del beneficiario según el género del titular

Género	Activos, n	Inactivos, n	Tasa de actividad, %
Mujeres	938	250	79,0
Hombres	619	142	81,3

   Nota. Tasa de actividad = activos/(activos + inactivos). Cálculos realizados a partir de los conteos proporcionados.

2. **¿Existe una relación entre el rango de edad de los beneficiarios y su estado de bancarización?**

   Los conteos disponibles muestran diferencias descriptivas entre los rangos de edad (véase la Tabla 2). Entre los registros clasificados como bancarizados o no bancarizados, la tasa es de 0,0 % para las personas de 6 a 17 años, 7,7 % para las de 18 a 29 y 70,8 % para las de 30 a 49. Sin embargo, faltan los conteos completos de los rangos de 50 a 65 años y mayores de 65, así como algunos valores ND. Por ello, estos resultados sugieren una asociación en los

grupos con datos disponibles, pero no permiten evaluar la relación para toda la población ni calificar su fuerza estadística.

Tabla 2

Estado de bancarización por rango de edad

Rango de edad	Bancarizados, n	No bancarizados, n	ND, n	Tasa, %
6–17 años	0	568	81	0,0
18–29 años	40	482	No indicado	7,7
30–49 años	293	121	No indicado	70,8
50–65 años	No indicado	No indicado	No indicado	No indicada
Más de 65 años	No indicado	No indicado	No indicado	No indicada

Nota. La tasa se calculó como bancarizados/(bancarizados + no bancarizados). ND se conserva tal como aparece en los datos. "No indicado" significa que el conteo no fue proporcionado.

3. **¿Cómo se distribuyen los rangos de beneficios asignados según el tipo de población (por ejemplo, Sisbén y otros grupos)?**

   La información proporcionada no incluye conteos ni porcentajes por tipo de población y rango de beneficio. Para completar esta respuesta, presente la tabla cruzada obtenida mediante SQL con las frecuencias y los porcentajes correspondientes; sin esos resultados no es posible describir la distribución de manera verificable.

4. **¿Cuál ha sido la tendencia histórica de las inscripciones de beneficiarios?**

   Según el resumen de resultados proporcionado, en 2012 se registraron 1 171 inscripciones, la mayor concentración observada. También se describe un comportamiento relativamente estable entre 2013 y 2018. Para respaldar esta conclusión, incluya los conteos anuales completos o una figura de la tendencia; esos valores no se proporcionaron aquí.

Actividades de apropiación

Fase 2 del proyecto integrador. A partir del conjunto de datos seleccionado en la actividad anterior, desarrolle las siguientes actividades.

Ficha de caracterización de variables

La Tabla 3 presenta el diccionario de variables elaborado a partir de la información disponible. Se recomienda verificar las categorías y sus definiciones con el archivo original y sus metadatos.

Tabla 3

Diccionario de variables del conjunto de datos

Variable	Descripción y categorías registradas	Nivel y tipo de dato
Bancarizado	Indica si la persona tiene cuenta bancaria. Categorías: Sí, No y ND.	Cualitativa, nominal; texto.
Código departamento de atención	Código del departamento; ejemplo: 15.	Cualitativa, nominal; texto identificador.
Código municipio de atención	Código del municipio; ejemplo: 15572.	Cualitativa, nominal; texto identificador.
Discapacidad	Indica si la persona reporta alguna discapacidad. Categorías: Sí, No y ND.	Cualitativa, nominal; texto.
Estado del beneficiario	Indica si el beneficiario está activo o inactivo.	Cualitativa, nominal; texto.
Etnia	Categorías registradas: Afroamericano-Nero, indígena, mestizo, ND, palenquero, raizal y Ron o gitano.	Cualitativa, nominal; texto.
Fecha de inscripción del beneficiario	Fecha en que se inscribió al beneficiario.	Temporal; fecha.
Género	Categorías registradas: hombre, mujer y ND.	Cualitativa, nominal; texto.
Nivel de escolaridad	Nivel educativo reportado: primaria, secundaria, sin especificar y transición.	Cualitativa, ordinal; texto.
Nombre del departamento de atención	Nombre del departamento; se registra Boyacá.	Cualitativa, nominal; texto.
Nombre del municipio de atención	Nombre del municipio; se registra Puerto Boyacá.	Cualitativa, nominal; texto.
País	Categorías registradas: Colombia, ND y 57.	Cualitativa, nominal; texto.
Tipo de asignación del beneficio	Tipo de asignación reportado: monetario o ND.	Cualitativa, nominal; texto.
Tipo de beneficio	Categorías registradas: nutrición, ND, educación primaria y nutrición, educación primaria, transición nutricional menor y educación secundaria.	Cualitativa, nominal; texto.
Tipo de documento	Categorías registradas: CC, TI, RC y no especificado.	Cualitativa, nominal; texto.
Tipo de población	Categorías registradas: desplazados, Sisbén, desplazados, unidos y ND.	Cualitativa, nominal; texto.

Variable	Descripción y categorías registradas	Nivel y tipo de dato
Rango del beneficio consolidado asignado	Agrupa el valor total de los beneficios acumulados o consolidados asignados al registro o usuario.	Cualitativa, ordinal; texto.
Rango del último beneficio asignado	Clasifica el valor del último beneficio individual otorgado al registro o usuario.	Cualitativa, ordinal; texto.
Fecha del último beneficio asignado	Fecha en que se asignó el beneficio más reciente.	Temporal; fecha.
Rango de edad	Segmento etario al que pertenece la persona registrada.	Cualitativa, ordinal; texto.
Titular	Indica si la persona es titular (Sí) o beneficiaria asociada (No).	Cualitativa, nominal; texto.
Cantidad de beneficiarios	Número total de personas adicionales asociadas al registro o dependientes del titular.	Cuantitativa, discreta; entero.

Nota. ND se conserva tal como aparece en la información disponible; su significado debe confirmarse en los metadatos. Las categorías “Nero”, “Ron o gitano” y el valor “57” también deben verificarse con el archivo original antes de estandarizarlos.

Limpieza de datos

Importe el archivo (.csv o .xlsx) en Google Colab y utilice bibliotecas y funciones de Python para limpiar los datos. Identifique y trate los valores nulos, elimine duplicados, ajuste los tipos de datos y realice las demás acciones que considere necesarias.

Análisis exploratorio de datos

Realice un análisis exploratorio de datos (EDA) e incluya los gráficos necesarios para comprender las relaciones entre las variables.

Actividades de transferencia del conocimiento

Fase 3 del proyecto integrador. Importe el conjunto de datos limpio en un entorno de base de datos relacional, como SQLiteOnline o una base integrada en Google Colab. Responda las preguntas de negocio formuladas en la fase de contextualización mediante consultas SQL que

utilicen, entre otras, las instrucciones `SELECT`, `WHERE`, `GROUP BY` y `JOIN`. Finalmente, consolide el proyecto en un único informe que presente las consultas realizadas y las conclusiones estratégicas obtenidas a partir de los datos.

Condiciones de entrega

1. Fecha de entrega: 31 de octubre de 2026 a las 12:00 a. m. (medianoche).
2. Presente las soluciones en un único documento con formato APA.
3. Suba el conjunto de datos, el cuaderno de Google Colab (.ipynb) y el documento de soluciones a su repositorio de GitHub.
4. Envíe por correo electrónico a `nmmartinez@sena.edu.co` su nombre y el enlace al repositorio de GitHub. Compruebe que el enlace funcione correctamente.
5. Cite a los autores de los conjuntos de datos cuando se indiquen. Si consulta fuentes en internet, incluya las referencias correspondientes.
6. Si utilizó alguna herramienta de inteligencia artificial (ChatGPT, Claude, Copilot, Gemini, DeepSeek, Perplexity, entre otras), indique en qué ejercicios la utilizó y en qué porcentaje.

Referencias

Jet Propulsion Laboratory. (1999, 30 de septiembre). *Mars Climate Orbiter team finds likely cause of loss*. NASA. `https://www.jpl.nasa.gov/news/mars-climate-orbiter-team-finds-likely-cause-of-loss/`

Mars Climate Orbiter Mishap Investigation Board. (2000). *Report on Project Management in NASA by the Mars Climate Orbiter Mishap Investigation Board (Phase II Report)*. NASA. `https://discovery.larc.nasa.gov/discovery/PDF_FILES/mars_climate_orbiter_phaseII.pdf`